

시간차 학습 알고리즘을 개선한 알고리즘: SARSA

- 특징 2개: Q-함수 사용,  $\epsilon$ -greedy 정책 사용

가장 좋은것만을 고르는 정책: 그리디 정책

$\epsilon$ 의 확률만큼 랜덤하게 움직이는 것:  $\epsilon$ -greedy 정책

SARSA의 정책: On-policy

Q-Learning의 정책: Off-policy

행동하는 정책과 학습할 때 사용하는 정책이 다른 것: Off-Policy

행동하는 정책이 학습할 때 사용하는 정책과 같은 것: On-Policy

SARSA 문제점: 평가시, 가끔은 랜덤으로 두기에, 평가 오류 가능

- Q-Learning?: 다음 수 부터는 올바르게 작동

행동가치 추정 시 분산이 높은 SARSA 단점 보완: Expected SARSA

절벽이 있는 그리드 월드에서 안전한 경로 선택: SALSA, 기대값 기반 SALSA

절벽이 있는 그리드 월드에서 최적 경로 선택: Q-Learning

학습 과정에서 입실론 감소: Epsilon 스케줄링

주어진 목적을 달성하기 위해 수행해야 할 일에 대한 방법 또는 절차 마련: 계획

- 예시: 동적 프로그래밍, 모델 기반 강화학습

주어진 대상과 직접 상호작용하며 목적을 달성하는 방법 또는 절차: 학습

- SARSA, Q-Learning, 모델 프리 강화학습

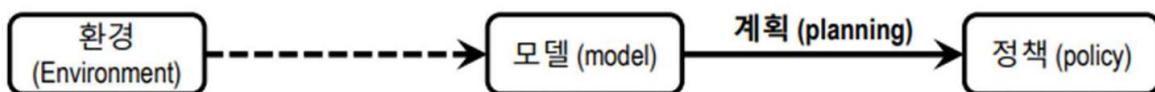
에이전트가 어떤 행동시 환경이 어떻게 반응할지 예측 위하여 사용하는 것: 모델

- 종류 2개: 분포 모델, 샘플 모델

모든 발생 가능한 상황 및 확률분포가 정확하게 기술: 분포 모델

발생 가능 상황 중 임의의 가능성만 샘플링 되는 모델: 샘플 모델

둘 중 더 용이한 것: 샘플 모델



임의의 정책을 통한 행동을 수행하여 상태 공간을 탐색: 상태 공간 계획

가치함수 계산 위해, 시뮬레이션 위한 경험데이터 기반 (역 갱신) 과정 수행

모델에 의하여 생성된 경험 샘플 데이터 사용: 계획

환경과의 직접 상호 작용을 통해 얻는 실제 경험 데이터 사용: 학습

온라인 계획 및 강화 학습이 동시에 수행되는 알고리즘: Dyna-Q

- 특징: 가치와 정책이 갱신되는 2개의 경로 존재

간접 모델 학습 및 계획: Q-Planning

- 장점: 샘플 효율성 높음, 한정 경험 정보 활용 직접 강화학습 보다 향상된 정책 산출 가능
- 단점: 모델 학습 불충분, 산출 정책에 편향

직접 강화학습: Q-Learning

- 환경과 직접적인 상호작용을 통하여 얻는 경험 바로 활용하여 정책 편향 경우 적음

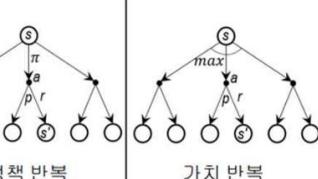
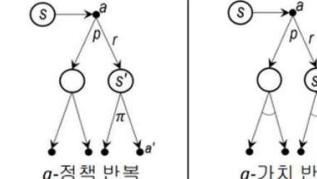
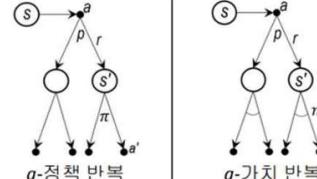
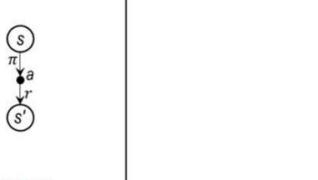
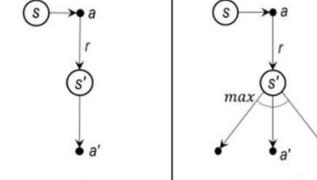
Dyna-Q 초기 시작: 탐험적 시작

- 행위 정책  $\epsilon$ -탐욕적 정책

갱신 대상에 다른 갱신 방법 2개: 상태 가치 갱신, 행동 가치 갱신

발생할 수 있는 모든 상황 고려 갱신: 기대 갱신

발생할 수 있는 간단한 단일 샘플 활용 갱신: 샘플 갱신

|   | 상태 가치<br>(State Value)   | 최적 상태 가치<br>(Optimal State Value)   | 행동 가치<br>(Action Value)  | 최적 행동 가치<br>(Optimal Action Value)   |
|---|--|---|--|--|
| 추정 가치<br>(Value Estimated)                  | $v_\pi(s)$   | $v_*(s)$  | $q_\pi(s, a)$  | $q_*(s, a)$  |
| 기대 갱신<br>(Expected Updates)<br>- 동적 프로그래밍   | <br>정책 반복<br>(policy iteration) | <br>가치 반복<br>(value iteration) | <br>q-정책 반복<br>(q-policy iteration) | <br>q-가치 반복<br>(q-value iteration) |
| 샘플 갱신<br>(Sample Updates)<br>- 단일 스텝 시간차 학습 | <br>$TD(0)$                     |   | <br>SARSA                           | <br>Q-Learning                     |

O: 해당 척도에 대하여 더 좋은 방법

|         | 샘플 갱신 (Sample Update) | 기대 갱신 (Expected Update) |
|---------|-----------------------|-------------------------|
| 계산량     | O                     |                         |
| 소요 시간   | O                     |                         |
| 정확도     |                       | O                       |
| 대표적인 기법 | Q-Learning            | 정책                      |

환경 또는환경 모델과 지속적으로 상호작용 하며 상태와 보상 얻어오는 일련의 과정: 궤적 샘플링

샘플링은 어떠한 (분포)에 입각하여 수행됨

샘플링 대상 후보들에 대해 어떠한 편중없이 임의로 선택: 균등분포 샘플링

현재 주어진 정책을 기반으로 각 상태의 행동 선택, 샘플링: On-policy 분포 샘플링

- 효과: 실제 일어날 법한 상황에 더 집중하여 가치함수 갱신

: 학습 효율 향상

