2026-1 자연어처리(20241519 조예성)

텍스트로부터 패턴이나 트렌드를 분석해서 고품질의 정보를 추출하는 과정:

텍스트 마이닝 과정: -> -> ->
- 전처리 종류 3개: , ,
- 토큰 종류 3개: , ,
- 특징값 추출 방법 3개: , ,
- 데이터분석 기법 4개: , , ,

말뭉치 영어로:

데이터에서 큰 의미 없는 단어 제거:

가지고 있는 코퍼스로부터 노이즈 데이터 제거:

표현 방법이 다른 단어들 통합:

모델이 학습에 사용할 정보 요소:

자연어 처리는 기술을 활용하여 데이터를 분석하고 가치를 찾아내는 응용 분야이다: O, X

용어	설명
	소리를 구별하는 최소 단위
	발음 단위
	의미를 가지는 최소 단위
	독립적으로 의미를 가지는 단위
	문장 내에서 의미 단위를 이루는 단어 묶음
	완전한 의미를 전달하는 단위
	하나 요지 설명 위해 전개한 문장 모임
문서	여러 문장으로 구성된 텍스트

텍스트 처리 최소 단위:
여러 토큰이 모여 의미를 이루는 단위:
여러 문장 모인 글:
여러 문서를 모아둔 데이터 집합:

사람이 보는 기준 토큰:

의미를 가지는 최소 단위: 형태소

모델 학습 위해 단어를 쪼갠 단위:

OOV 처리 가능한 것:
- 뜻:

자연어 처리 과정: - - - -

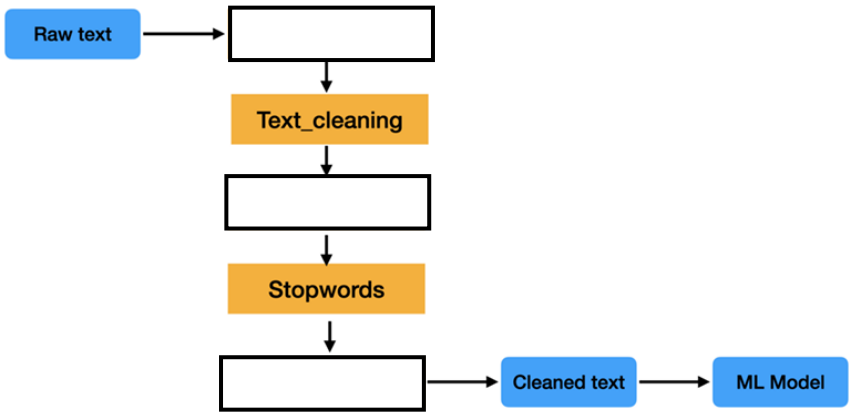

단어에서 변하지 않는 부분:

단어를 사전의 기본형으로 변환:

단어를 문법적 기능에 따라 분류한 것:

한국어 특징으로 단어 하나에 여러 문법 요소가 붙는 구조:

영어: | 한국어:

여러 개의 숫자를 일렬로 배열한 것:

벡터의 공간적 의미:

유사도 측정 방식 2개: ,

A (2,1,0,1,2) B (1,2,2,0,1)의 코사인 거리:

문서에 등장하는 단어의 빈도를 이용하여 문서를 벡터화:

문서로 원핫 인코딩:
- 단점:

문서에서 단어 중요도 계산:

문서	파이썬	JSP
문서 1	10	0
문서 2	6	2

'JSP'가 등장한 문서 수DF와 IDF
문서 1의 'JSP' TF-IDF
문서 2의 '파이썬' TF-IDF
문서 2의 'JSP' $TF-IDF

학습 데이터셋에 포함된 데이터가 아닌 새로운 데이터에서 잘 동작하는지 여부:

특성 정보 없이 분류 확률 추정:

특성 정보(단어) 있이 확률 추정:

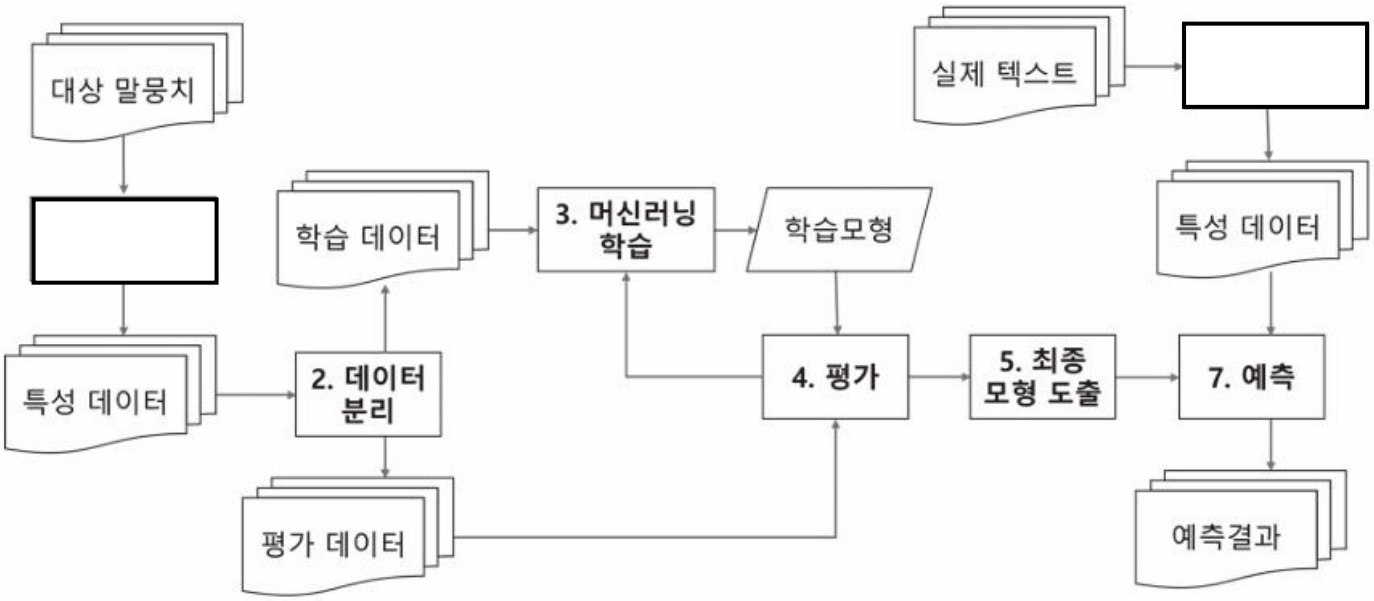

각 사건의 확률이 타 사건의 확률에 영향이 없을 때 ( ) 이라고 함

어떤 사건이 일어난다고 했을 때 다른 사건이 일어날 확률:

두 변수 간 사전확률과 사후확률 사이의 관계를 나타내는 정리:
- 전제:

이진 분류 문제를 확률로:

어떤 사건이 일어날 확률과 일어나지 않을 확률의 비율:
- 에 로그 적용:
  -의 역함수:

목적함수에 추정할 계수에 대한 규제항 추가 과적합 방지:

L1 norm을 규제항으로 사용, 0에 가까운 계수를 0으로:
- ( )의 효과가 있음

노드와 노드를 연결하는 간선:

뿌리부터 잎 노드까지 깊이:

분할 속성 지수: ,

사건이 일어날 확률을 통해 계산한 정보량:

모델 평가 지표
- 회귀: , , ,
- 분류: , , , , ,

예측값이 실제값 대비 얼마나 잘 맞는지 2x2 행렬로:

정확도:

정밀도:

민감도(recall):

F1 스코어:
- 식:

문맥을 파악한 처리 위한 방법:

언어 모델이 계산하는 것:

현재 상태가 과거의 일정 기간 만을 기반으로 결정된다고 가정하는 확률:

각 단어의 독립적인 확률로 계산:

이전 단어 1개를 고려한 조건부 확률 사용, 단어 순서 반영 가능:
- 이전 단어 2개:

N의 크기가 커지면 정확도( ), 비용( )
희소성 문제 해결: , , ,

n그램의 확률 부족할 때로 내려가 계산:

여러 차수의 n그램 확률 가중합:

모든 단어에 1 더하기:

카운트 있는 n그램의 빈도에서 일정 값 빼서 확률 재분배:

대규모 문서 집합 내에 숨겨진 추상적인 주제를 발견하기 위한 통계적 모델링 기법:

내재된 주제는 추상적이다: O, X

문서-단어 행렬(DTM)에 특잇값 분해(SVD)를 적용하여 데이터 차원 축소:

문서는 토픽의 혼합체, 토픽은 특정 단어의 확률 분포라는 확률적 가설:

특이값 행렬, 단어-주제 행렬, 문서-주제 행렬 이용:

LDA는 문서마다 ( )를 생성한다

- 각 토픽마다 ( )를 생성

LDA가 사용하는 분포:
- 디리클레 분포는 각 요소의 합이 ( )

LDA의 성능 척도 2개: ,

감성 분류 3개: , ,
- 정도:

어휘 기반의 감성 분석은 ( )을 이용한다

밑의 단어부터 상위의 구로 구로 이동하면서 단계적으로 결정:

머신러닝 기반의 감정분석:

단점:
장점:

예측값-실제값이 가까워 지도록 가중치 조절하는 과정:

경사하강법 이용한 학습 규칙 명칭:

XOR 연산 퍼셉트론으로:

여러 층의 퍼셉트론이 결합된 인공 신경망 구조:

비정형 데이터 종류: , , ,

Input, Output 의 node 수 결정:
- Hidden Layer 노드 수:
- 가중치 추정:

모델의 예측값과 실제값의 차이를 수치로 나타내는 함수:
- 이진분류:
- 다중 분류:

모델의 오차를 최소화 하는 최적의 가중치를 찾는 최적화 알고리즘:

다중 분류 모델의 정답지는 ( )을 사용한다

역전파 갱신시 사용되는 법칙:

회귀 모델 성능 평가 지표:

분류 모델 성능 평가 지표:

활성화 함수는 주로 ( ) 함수 사용
- 단점: , ,

입력 신호 그대로 출력:
0~ 사이 값으로 변환:
출력값을 확률 분포로 변환:

신경망 적합 3종류: , ,

기울기 소실 해결법: , , , , ,

경사하강법 문제:
- 개선: , , ,

모델이 다양한 상황에서 안정적으로 동작하는 일반화 된 성능 뜻:

설명	평가지표
찍어도 모름	
찍어서 맞추는 것 보정	
정규화된 상호 정보량, 군집 정답 힌트	

단어의 순위와 출현 빈도가 반비례한다는 법칙 (자주 등장하는 단어는 극소수):

두 점 사이의 최단 직선 거리를 구하는 방식 (차이의 제곱합에 루트):

두 점 사이를 격자(수직/수평)로만 이동할 때의 거리 (절댓값의 합):

길이가 같은 두 데이터에서 서로 다른 값을 가지는 위치의 개수:

데이터를 분리하는 최적의 결정 경계(초평면, Margin)를 찾아 분류하는 알고리즘:

여러 개의 결정 트리를 생성하고 그 결과를 투표(Voting)하여 예측하는 앙상블 기법:

데이터의 분산(Variance)을 최대한 보존하는 새로운 직교 축을 찾아 차원을 축소하는 기법:

차원이 늘어남에 따라 데이터 공간이 기하급수적으로 커지고 분포가 희박해지는 현상:

사전에 정해진 K개의 중심점(Centroid)을 기준으로 가장 가까운 데이터들을 묶는 군집화 방식:

최적의 군집 수 K를 찾기 위해 오차 제곱합(WCSS) 감소율이 꺾이는 지점을 찾는 방법:

데이터가 여러 개의 정규분포가 섞인 형태에서 생성되었다고 가정하는 확률 기반 군집 모델:

GMM에서 숨겨진 파라미터를 추정하기 위해 기댓값(E)과 최대화(M) 단계를 반복하는 알고리즘:

전체 학습 데이터셋을 신경망에 통과시키는 1번의 학습 주기:

한 번의 가중치 업데이트를 위해 모델에 한 번에 입력되는 데이터의 묶음 크기:

전체 데이터셋 대신 하나의 데이터 포인트 또는 작은 미니배치를 사용하여 가중치를 업데이트하는 방식:

이전 업데이트의 방향(관성)을 현재 업데이트에 반영하여 탐색을 빠르고 안정적으로 하는 최적화 기법:

문제 1.

2차원 공간의 두 벡터 $A(3, 4)$ 와 $B(4, 3)$ 의 코사인 거리를 구하시오.

문제 2.

2차원 공간의 두 벡터 $C(1, 0)$ 와 $D(0, 1)$ 의 코사인 거리를 구하시오.

문제 3.

3차원 공간의 두 벡터 $E(1, 2, 2)$ 와 $F(2, 2, 1)$ 의 코사인 거리를 구하시오.

문제 4.

3차원 공간의 두 벡터 $G(2, -1, 2)$ 와 $H(-2, 1, -2)$ 의 코사인 거리를 구하시오.

문제 5.

4차원 공간의 두 벡터 $I(1, 1, 1, 1)$ 와 $J(1, -1, 1, -1)$ 의 코사인 거리를 구하시오.

해설 1.

- 내적: $(3 \times 4) + (4 \times 3) = 24$
- 크기: $|A| = 5, |B| = 5$
- 코사인 유사도: $\frac{24}{25} = 0.96$
- **코사인 거리:** $1 - 0.96 = 0.04$

해설 2.

- 내적: $(1 \times 0) + (0 \times 1) = 0$
- 크기: $|C| = 1, |D| = 1$
- 코사인 유사도: $\frac{0}{1} = 0$ (두 벡터가 90° 로 직교함)
- **코사인 거리:** $1 - 0 = 1$

해설 3.

- 내적: $(1 \times 2) + (2 \times 2) + (2 \times 1) = 2 + 4 + 2 = 8$
- 크기: $|E| = \sqrt{1^2 + 2^2 + 2^2} = 3, |F| = \sqrt{2^2 + 2^2 + 1^2} = 3$
- 코사인 유사도: $\frac{8}{3 \times 3} = \frac{8}{9}$
- **코사인 거리:** $1 - \frac{8}{9} = \frac{1}{9}$ (약 0.1111)

해설 4.

- 내적: $(2 \times -2) + (-1 \times 1) + (2 \times -2) = -4 - 1 - 4 = -9$
- 크기: $|G| = 3, |H| = 3$
- 코사인 유사도: $\frac{-9}{9} = -1$ (두 벡터가 완전히 반대 방향을 향함)
- **코사인 거리:** $1 - (-1) = 2$ (코사인 거리가 가질 수 있는 최댓값)

해설 5.

- 내적: $(1 \times 1) + (1 \times -1) + (1 \times 1) + (1 \times -1) = 1 - 1 + 1 - 1 = 0$
- 크기: $|I| = 2, |J| = 2$
- 코사인 유사도: $\frac{0}{4} = 0$
- **코사인 거리:** $1 - 0 = 1$

📝 세상에서 가장 쉬운 편미분 문제

문제 1. [독립적인 변수의 덧셈]
어떤 결과값이 $f(x, y) = x + y$ 로 결정됩니다. 이 함수를 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.

문제 2. [계수가 붙은 덧셈]
이번에는 $f(x, y) = 3x + 5y$ 입니다. 이 함수를 y에 대해 편미분한 식 $\frac{\partial f}{\partial y}$ 를 구하시오.

문제 3. [기초적인 곱셈]
두 변수가 곱해진 $f(x, y) = x \times y$ 가 있습니다. 이 함수를 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.

📝 실제 값을 대입하는 편미분 계산 문제

문제 4. [기본 다항식의 미분과 값 대입]
어떤 수식이 $f(x, y) = x^2 + 4xy$ 로 주어졌습니다.

1. 이 수식을 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.
2. 현재 값이 $x = 2, y = 3$ 일 때, 이 기울기의 최종 숫자 값을 계산하시오.

문제 5. [가중치 업데이트 기초 계산]
인공신경망의 오차(Loss) 함수가 두 가중치 w_1, w_2 에 의해 $L(w_1, w_2) = 2w_1^2 + w_1w_2 + w_2^2$ 로 결정됩니다.

1. 가중치 w_1 에 대한 편미분 식 $\frac{\partial L}{\partial w_1}$ 을 구하시오.
2. 현재 가중치가 $w_1 = 3, w_2 = 4$ 일 때, w_1 을 업데이트하기 위한 기울기 값을 계산하시오.

문제	해설	정답
문제 1	y는 단순한 숫자(예: 10)로 취급합니다. 숫자를 미분하면 0이 되어 사라지고, x를 미분하면 1이 됩니다. 따라서 $\frac{\partial f}{\partial x} = 1 + 0 = 1$ 입니다.	1
문제 2	x에 대한 식 $3x$는 숫자로 취급되어 미분하면 0이 됩니다. $5y$를 y에 대해 미분하면 y 앞의 계수인 5만 남습니다. 따라서 $\frac{\partial f}{\partial y} = 0 + 5 = 5$ 입니다.	5
문제 3	y를 3이나 5 같은 단순한 상수로 생각해보세요. 만약 식이 $3x$ 라면 미분 결과는 3이 될 것입니다. 마찬가지로 $x \times y$ 를 x로 미분하면 옆에 곱해져 있던 '숫자 취급된' y만 남게 됩니다.	y
문제 4	**1. 편미분하기:** y는 숫자(상수) 취급합니다. x^2을 미분하면 $2x$가 되고, $4xy$에서 $4y$는 숫자이므로 x로 미분하면 $4y$만 남습니다. 즉, 편미분 식은 $2x + 4y$ 입니다. **2. 값 대입하기:** 도출된 식에 $x = 2, y = 3$ 을 대입합니다. $2(2) + 4(3) = 4 + 12 = 16$	편미분 식: $2x + 4y$ 최종 값: 16
문제 5	**1. 편미분하기:** w_2는 숫자(상수) 취급합니다. $2w_1^2$을 w_1로 미분하면 $4w_1$이 됩니다. w_1w_2를 w_1로 미분하면 w_2만 남습니다. w_2^2는 w_1이 아예 없으므로 단순한 숫자로 취급되어 미분하면 0이 되어 사라집니다. 즉, 편미분 식은 $4w_1 + w_2$ 입니다. **2. 값 대입하기:** 도출된 식에 $w_1 = 3, w_2 = 4$ 를 대입합니다. $4(3) + 4 = 12 + 4 = 16$	편미분 식: $4w_1 + w_2$ 최종 값: 16