2026-1 자연어처리(20241519 조예성)

텍스트로부터 패턴이나 트렌드를 분석해서 고품질의 정보를 추출하는 과정: 텍스트 마이닝

텍스트 마이닝 과정: 텍스트 전처리->토큰화->특징값 추출->데이터 분석
- 전처리 종류 3개: 정제, 정규화, 품사태깅
- 토큰 종류 3개: 단어 토큰, 형태소 토큰, 서브워드 토큰
- 특징값 추출 방법 3개: Bag of Words, TF-IDF, Embedding
- 데이터분석 기법 4개: 시각화, 통계분석, 데이터마이닝, 머신러닝

말뭉치 영어로: corpus

데이터에서 큰 의미 없는 단어 제거: 불용어 제거

가지고 있는 코퍼스로부터 노이즈 데이터 제거: 정제

표현 방법이 다른 단어들 통합: 정규화

모델이 학습에 사용할 정보 요소: 특징값

자연어 처리는 기술을 활용하여 데이터를 분석하고 가치를 찾아내는 응용 분야이다: O, **X**

용어	설명
음소	소리를 구별하는 최소 단위
음절	발음 단위
형태소	의미를 가지는 최소 단위
단어	독립적으로 의미를 가지는 단위
구	문장 내에서 의미 단위를 이루는 단어 묶음
문장	완전한 의미를 전달하는 단위
문단	하나 요지 설명 위해 전개한 문장 모임
문서	여러 문장으로 구성된 텍스트

텍스트 처리 최소 단위: 토큰
여러 토큰이 모여 의미를 이루는 단위: 문장
여러 문장 모인 글: 문서
여러 문서를 모아둔 데이터 집합: 말뭉치

사람이 보는 기준 토큰: 단어 토큰화

의미를 가지는 최소 단위: 형태소 토큰화

모델 학습 위해 단어를 쪼갠 단위: 서브워드

OOV 처리 가능한 것: 서브워드
- 뜻: 사전에 없더라도 가능

자연어 처리 과정: 텍스트-전처리-토큰화-벡터화-분석

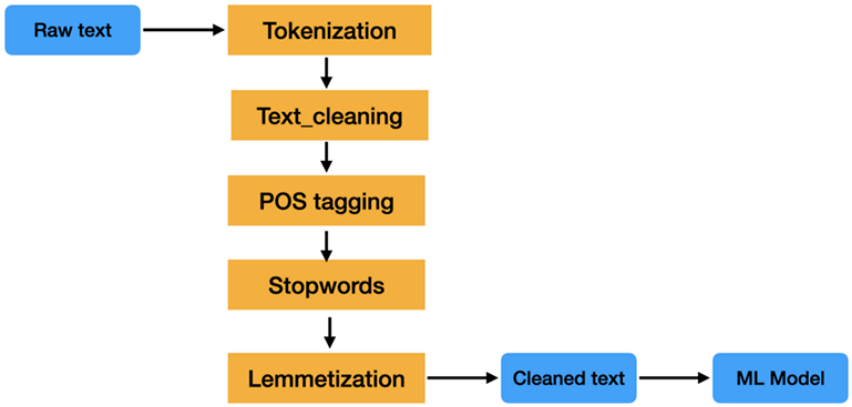

단어에서 변하지 않는 부분: 어간

단어를 사전의 기본형으로 변환: 표제어 추출

단어를 문법적 기능에 따라 분류한 것: 품사 태깅

한국어 특징으로 단어 하나에 여러 문법 요소가 붙는 구조: 교착어

영어: 굴절어 | 한국어: 교착어

여러 개의 숫자를 일렬로 배열한 것: 벡터

벡터의 공간적 의미: 공간상의 점

유사도 측정 방식 2개: 거리 기반 추천, 각도 기반 추천

A (2,1,0,1,2) B (1,2,2,0,1)의 코사인 거리: 0.4

문서에 등장하는 단어의 빈도를 이용하여 문서를 벡터화: 카운트 기반 문서표현

문서로 원핫 인코딩: DTM
- 단점: 희소벡터

문서에서 단어 중요도 계산: TF-IDF

문서	파이썬	JSP
문서 1	10	0
문서 2	6	2

'JSP'가 등장한 문서 수DF와 IDF
문서 1의 'JSP' TF-IDF
문서 2의 '파이썬' TF-IDF
문서 2의 'JSP' $TF-IDF

학습 데이터셋에 포함된 데이터가 아닌 새로운 데이터에서 잘 동작하는지 여부: 일반화 성능

특성 정보 없이 분류 확률 추정: 사전확률

특성 정보(단어) 있이 확률 추정: 사후 확률

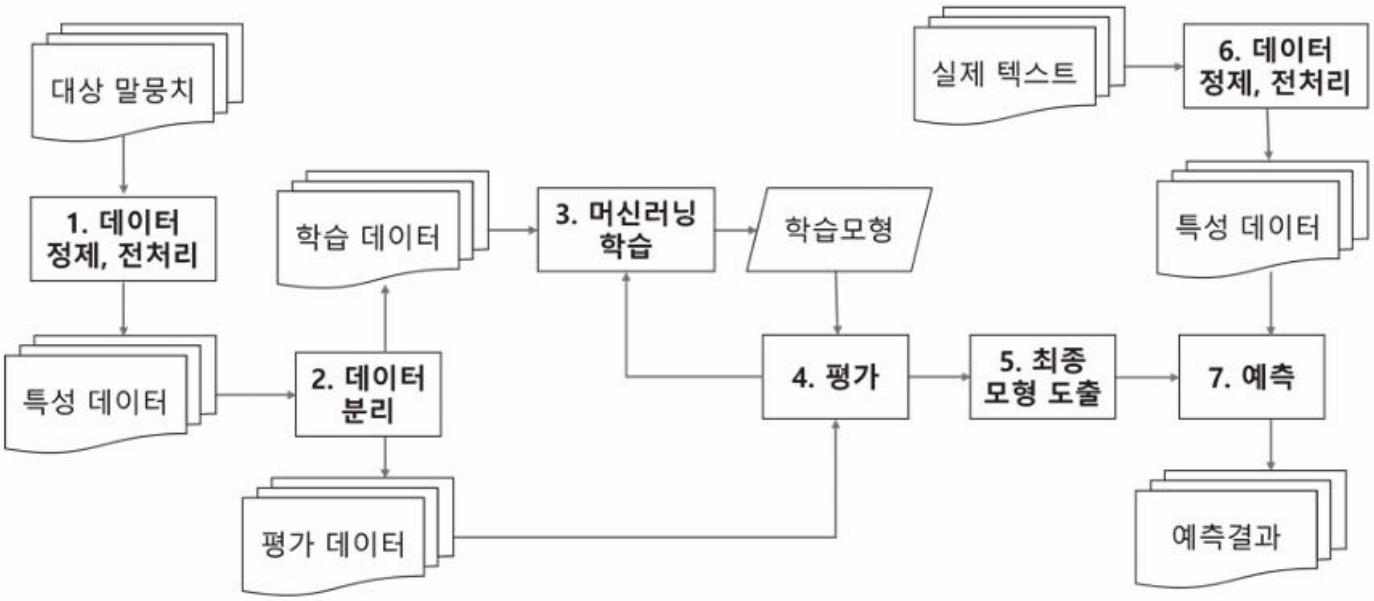

각 사건의 확률이 타 사건의 확률에 영향이 없을 때 (독립) 이라고 함

어떤 사건이 일어난다고 했을 때 다른 사건이 일어날 확률: 조건부 확률

두 변수 간 사전확률과 사후확률 사이의 관계를 나타내는 정리: 베이즈 정리
- 전제: 객관적 확률 존재 없이 이전 사건으로 인해 확률이 지속적으로 업데이트

이진 분류 문제를 확률로: 로지스틱 회귀

어떤 사건이 일어날 확률과 일어나지 않을 확률의 비율: 오즈비
- 에 로그: 로짓
  -의 역함수: 로지스틱 함수

목적함수에 추정할 계수에 대한 규제항 추가 과적합 방지: 릿지 회귀

L1 norm을 규제항으로 사용, 0에 가까운 계수를 0으로: 라쏘 회귀
- (특성 선택)의 효과가 있음

노드와 노드를 연결하는 간선: 엣지

뿌리부터 잎 노드까지 깊이: 높이

분할 속성 지수: 엔트로피 지수, 지니 계수

사건이 일어날 확률을 통해 계산한 정보량: 엔트로피

모델 평가 지표
- 회귀: MAE, MSE, RMSE, SSE
- 분류: 정확도, 정밀도, 민감도, F1 스코어, ROC 커브, 리프트 차트
- 군집: DBI, 엘보우 메서드, 실루엣 계수

예측값이 실제값 대비 얼마나 잘 맞는지 2x2 행렬로: 혼동행렬

정확도: 전체 데이터 개수 대비 얼마나 맞췄는지

정밀도: 참에 대해서 얼마나 잘 맞출지

민감도(recall): 참을 얼마나 누락 없이 참이라고 예측했는지

F1 스코어: 정밀도와 민감도의 조화평균
- 식: 2 * ((정밀도*민감도) / (정밀도+민감도))

문맥을 파악한 처리 위한 방법: NGRAM

언어 모델이 계산하는 것: 단어 시퀀스의 확률

현재 상태가 과거의 일정 기간 만을 기반으로 결정된다고 가정하는 확률 모데리 마르코프 모델

각 단어의 독립적인 확률로 계산: Unigram

이전 단어 1개를 고려한 조건부 확률 사용, 단어 순서 반영 가능: Bigram
- 이전 단어 2개: Trigram

N의 크기가 커지면 정확도(상승), 비용(상승)
희소성 문제 해결: Back-off smoothing, Linear interpolation, Laplace smoothing, Absolute Discounting

n그램의 확률 부족할 때로 내려가 계산: Back-off smoothing

여러 차수의 n그램 확률 가중합: Linear interpolation

모든 단어에 1 더하기: Laplace smoothing

카운트 있는 n그램의 빈도에서 일정 값빼서 확률 재분배: Absolute Discounting

대규모 문서 집합 내에 숨겨진 추상적인 주제를 발견하기 위한 통계적 모델링 기법: 토픽 모델링

내재된 주제는 추상적이다: **O,** X

문서-단어 행렬(DTM)에 특잇값 분해(SVD)를 적용하여 데이터 차원 축소: LSI

문서는 토픽의 혼합체, 토픽은 특정 단어의 확률 분포라는 확률적 가설: LDA

특이값 행렬, 단어-주제 행렬, 문서-주제 행렬 이용: Truncated SVD

LDA는 문서마다 (토픽 분포 세타)를 생성한다

- 각 토픽마다 (단어 분포 phi)를 생성

LDA가 사용하는 분포: 디리클레 분포
- 디리클레 분포는 각 요소의 합이 (1)

LDA의 성능 척도 2개: 혼란도, 토픽 응집도

감성 분류 3개: 긍정, 중립, 부정
- 정도: 극성

어휘 기반의 감성 분석은 (감성 사전)을 이용한다

밑의 단어부터 상위의 구로 구로 이동하면서 단계적으로 결정: 문장구조분석

머신러닝 기반의 감정분석: 로지스틱 회귀 분석

단점: 데이터에 의존적
장점: 전이학습 가능

예측값-실제값이 가까워 지도록 가중치 조절하는 과정: 학습

경사하강법 이용한 학습 규칙 명칭: Delta 규칙

XOR 연산 퍼셉트론으로: NAND 과 OR 결과에 AND 연산

여러 층의 퍼셉트론이 결합된 인공 신경망 구조: 다층 퍼셉트론

비정형 데이터 종류: 이미지, 텍스트, 음성, 시계열

Input, Output 의 node 수 결정: Domain
- Hidden Layer 노드 수: 실험
- 가중치 추정: Back-Propagation

모델의 예측값과 실제값의 차이를 수치로 나타내는 함수: 손실 함수
- 이진분류: Binarry Crossentropy
- 다중 분류: Categorical Crossentropy

모델의 오차를 최소화 하는 최적의 가중치를 찾는 최적화 알고리즘: 경사하강법

다중 분류 모델의 정답지는 (원 핫 인코딩)을 사용한다

역전파 갱신시 사용되는 법칙: 연쇄 법칙

회귀 모델 성능 평가 지표: 결정계수(R^2)

분류 모델 성능 평가 지표: 혼동 행렬

활성화 함수는 주로 (비선형) 함수 사용
- 단점: 기울기 소실 및 폭주, 계산 비용, 설명 가능성 저하

입력 신호 그대로 출력: 항등함수
0~ 사이 값으로 변환: 시그모이드
출력값을 확률 분포로 변환: 소프트맥스

신경망 적합 3종류: 과소적합, 정적합, 과대적합

기울기 소실 해결법: 가중치 초기화, 배치 정규화, 데이터 증강, 잡음 주입, ReLU, 앙상블

경사하강법 문제: 지역최저점
- 개선: 확률적, 미니배치, 모멘텀, 아담

모델이 다양한 상황에서 안정적으로 동작하는 일반화 된 성능 뜻: 강건성

설명	평가지표
찍어도 모름	Rand Index
찍어서 맞추는 것 보정	ARI
정규화된 상호 정보량, 군집 정답 힌트	NMI

단어의 순위와 출현 빈도가 반비례한다는 법칙 (자주 등장하는 단어는 극소수): 지프의 법칙 (Zipf's law)

두 점 사이의 최단 직선 거리를 구하는 방식 (차이의 제곱합에 루트): 유클리드 거리

두 점 사이를 격자(수직/수평)로만 이동할 때의 거리 (절댓값의 합): 맨해튼 거리

길이가 같은 두 데이터에서 서로 다른 값을 가지는 위치의 개수: 해밍 거리

데이터를 분리하는 최적의 결정 경계(초평면, Margin)를 찾아 분류하는 알고리즘: SVM

여러 개의 결정 트리를 생성하고 그 결과를 투표(Voting)하여 예측하는 앙상블 기법: 랜덤 포레스트 (Random Forest)

데이터의 분산(Variance)을 최대한 보존하는 새로운 직교 축을 찾아 차원을 축소하는 기법: PCA (주성분 분석)

차원이 늘어남에 따라 데이터 공간이 기하급수적으로 커지고 분포가 희박해지는 현상: 차원의 저주

사전에 정해진 K개의 중심점(Centroid)을 기준으로 가장 가까운 데이터들을 묶는 군집화 방식: K-Means (K-평균 군집화)

최적의 군집 수 K를 찾기 위해 오차 제곱합(WCSS) 감소율이 꺾이는 지점을 찾는 방법: 엘보우 메서드

데이터가 여러 개의 정규분포(가우시안 분포)가 섞인 형태에서 생성되었다고 가정하는 확률 기반 군집 모델: GMM (가우시안 혼합 모델)

GMM에서 숨겨진 파라미터를 추정하기 위해 기댓값(E)과 최대화(M) 단계를 반복하는 알고리즘: EM 알고리즘

전체 학습 데이터셋을 신경망에 통과시키는 1번의 학습 주기: 에포크 (Epoch)

한 번의 가중치 업데이트를 위해 모델에 한 번에 입력되는 데이터의 묶음 크기: 배치 사이즈 (Batch Size)

전체 데이터셋 대신 하나의 데이터 포인트 또는 작은 미니배치를 사용하여 가중치를 업데이트하는 방식: 확률적 경사하강법 (SGD)

이전 업데이트의 방향(관성)을 현재 업데이트에 반영하여 탐색을 빠르고 안정적으로 하는 최적화 기법: 모멘텀 (Momentum)

문제 1.

2차원 공간의 두 벡터 $A(3, 4)$ 와 $B(4, 3)$ 의 코사인 거리를 구하시오.

문제 2.

2차원 공간의 두 벡터 $C(1, 0)$ 와 $D(0, 1)$ 의 코사인 거리를 구하시오.

문제 3.

3차원 공간의 두 벡터 $E(1, 2, 2)$ 와 $F(2, 2, 1)$ 의 코사인 거리를 구하시오.

문제 4.

3차원 공간의 두 벡터 $G(2, -1, 2)$ 와 $H(-2, 1, -2)$ 의 코사인 거리를 구하시오.

문제 5.

4차원 공간의 두 벡터 $I(1, 1, 1, 1)$ 와 $J(1, -1, 1, -1)$ 의 코사인 거리를 구하시오.

해설 1.

- 내적: $(3 \times 4) + (4 \times 3) = 24$
- 크기: $|A| = 5, |B| = 5$
- 코사인 유사도: $\frac{24}{25} = 0.96$
- **코사인 거리:** $1 - 0.96 = 0.04$

해설 2.

- 내적: $(1 \times 0) + (0 \times 1) = 0$
- 크기: $|C| = 1, |D| = 1$
- 코사인 유사도: $\frac{0}{1} = 0$ (두 벡터가 90° 로 직교함)
- **코사인 거리:** $1 - 0 = 1$

해설 3.

- 내적: $(1 \times 2) + (2 \times 2) + (2 \times 1) = 2 + 4 + 2 = 8$
- 크기: $|E| = \sqrt{1^2 + 2^2 + 2^2} = 3, |F| = \sqrt{2^2 + 2^2 + 1^2} = 3$
- 코사인 유사도: $\frac{8}{3 \times 3} = \frac{8}{9}$
- **코사인 거리:** $1 - \frac{8}{9} = \frac{1}{9}$ (약 0.1111)

해설 4.

- 내적: $(2 \times -2) + (-1 \times 1) + (2 \times -2) = -4 - 1 - 4 = -9$
- 크기: $|G| = 3, |H| = 3$
- 코사인 유사도: $\frac{-9}{9} = -1$ (두 벡터가 완전히 반대 방향을 향함)
- **코사인 거리:** $1 - (-1) = 2$ (코사인 거리가 가질 수 있는 최댓값)

해설 5.

- 내적: $(1 \times 1) + (1 \times -1) + (1 \times 1) + (1 \times -1) = 1 - 1 + 1 - 1 = 0$
- 크기: $|I| = 2, |J| = 2$
- 코사인 유사도: $\frac{0}{4} = 0$
- **코사인 거리:** $1 - 0 = 1$

📝 세상에서 가장 쉬운 편미분 문제

문제 1. [독립적인 변수의 덧셈]
어떤 결과값이 $f(x, y) = x + y$ 로 결정됩니다. 이 함수를 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.

문제 2. [계수가 붙은 덧셈]
이번에는 $f(x, y) = 3x + 5y$ 입니다. 이 함수를 y에 대해 편미분한 식 $\frac{\partial f}{\partial y}$ 를 구하시오.

문제 3. [기초적인 곱셈]
두 변수가 곱해진 $f(x, y) = x \times y$ 가 있습니다. 이 함수를 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.

📝 실제 값을 대입하는 편미분 계산 문제

문제 4. [기본 다항식의 미분과 값 대입]
어떤 수식이 $f(x, y) = x^2 + 4xy$ 로 주어졌습니다.

1. 이 수식을 x에 대해 편미분한 식 $\frac{\partial f}{\partial x}$ 를 구하시오.
2. 현재 값이 $x = 2, y = 3$ 일 때, 이 기울기의 최종 숫자 값을 계산하시오.

문제 5. [가중치 업데이트 기초 계산]
인공신경망의 오차(Loss) 함수가 두 가중치 w_1, w_2 에 의해 $L(w_1, w_2) = 2w_1^2 + w_1w_2 + w_2^2$ 로 결정됩니다.

1. 가중치 w_1 에 대한 편미분 식 $\frac{\partial L}{\partial w_1}$ 을 구하시오.
2. 현재 가중치가 $w_1 = 3, w_2 = 4$ 일 때, w_1 을 업데이트하기 위한 기울기 값을 계산하시오.

문제	해설	정답
문제 1	y는 단순한 숫자(예: 10)로 취급합니다. 숫자를 미분하면 0이 되어 사라지고, x를 미분하면 1이 됩니다. 따라서 $\frac{\partial f}{\partial x} = 1 + 0 = 1$ 입니다.	1
문제 2	x에 대한 식 $3x$는 숫자로 취급되어 미분하면 0이 됩니다. $5y$를 y에 대해 미분하면 y 앞의 계수인 5만 남습니다. 따라서 $\frac{\partial f}{\partial y} = 0 + 5 = 5$ 입니다.	5
문제 3	y를 3이나 5 같은 단순한 상수로 생각해보세요. 만약 식이 $3x$ 라면 미분 결과는 3이 될 것입니다. 마찬가지로 $x \times y$ 를 x로 미분하면 옆에 곱해져 있던 '숫자 취급된' y만 남게 됩니다.	y
문제 4	**1. 편미분하기:** y는 숫자(상수) 취급합니다. x^2을 미분하면 $2x$가 되고, $4xy$에서 $4y$는 숫자이므로 x로 미분하면 $4y$만 남습니다. 즉, 편미분 식은 $2x + 4y$ 입니다. **2. 값 대입하기:** 도출된 식에 $x = 2, y = 3$ 을 대입합니다. $2(2) + 4(3) = 4 + 12 = 16$	편미분 식: $2x + 4y$ 최종 값: 16
문제 5	**1. 편미분하기:** w_2는 숫자(상수) 취급합니다. $2w_1^2$을 w_1로 미분하면 $4w_1$이 됩니다. w_1w_2를 w_1로 미분하면 w_2만 남습니다. w_2^2는 w_1이 아예 없으므로 단순한 숫자로 취급되어 미분하면 0이 되어 사라집니다. 즉, 편미분 식은 $4w_1 + w_2$ 입니다. **2. 값 대입하기:** 도출된 식에 $w_1 = 3, w_2 = 4$ 를 대입합니다. $4(3) + 4 = 12 + 4 = 16$	편미분 식: $4w_1 + w_2$ 최종 값: 16